Detección de fraude en transacciones financieras con aprendizaje de máquina

Samuel Puerta Patiño, Simón Berrio Gaviria y Juan Estiven Carmona Muñoz

***Resumen*—Este trabajo aborda la detección de transacciones fraudulentas como un problema de clasificación binaria supervisada sobre un conjunto sintético de 10 000 transacciones con solo 1,26 % de fraudes. El análisis exploratorio muestra que el fraude no se asocia con el monto, las variables categóricas, el momento de la transacción ni el historial del usuario; la única señal está en un puntaje de riesgo precalculado, que separa cerca de una cuarta parte de los fraudes y que podría constituir una fuga de información. Se describe la fase de caracterización, en la que el registro de transacciones se transforma en un espacio de 35 características que incluye variables temporales y de comportamiento por usuario, y se revisa la literatura especializada para definir la metodología de validación y las métricas que se usarán en las siguientes etapas del proyecto.**

***Index Terms*—Detección de fraude, clases desbalanceadas, caracterización, aprendizaje supervisado, datos sintéticos.**

I. Introducción

El fraude en transacciones financieras es el uso no autorizado de medios de pago o de cuentas para obtener un beneficio ilegítimo. Crece con la expansión de los pagos electrónicos y genera pérdidas importantes a entidades financieras y clientes [1], [2]. Este documento presenta las dos primeras etapas del proyecto: la descripción del problema, incluyendo el análisis exploratorio y la caracterización de los datos (Sección II), y la revisión del estado del arte (Sección III).

II. Descripción del problema

II-A. Contexto

Los sistemas basados en reglas definidas manualmente no escalan al volumen actual de transacciones ni capturan patrones que no son evidentes para un analista, por lo que el aprendizaje de máquina (ML) se ha convertido en la alternativa más estudiada para esta tarea [1]. El problema es difícil por dos razones: la fuerte desproporción entre transacciones legítimas y fraudulentas [2], [3] y el solapamiento entre ambas clases en el espacio de características [2]. Además, los errores no cuestan lo mismo: un fraude no detectado implica una pérdida directa, mientras que una falsa alarma solo genera una revisión innecesaria. Un modelo entrenado con transacciones etiquetadas permitiría asignar a cada transacción nueva una probabilidad de fraude y decidir, con base en ella, si se aprueba, se bloquea o se envía a revisión manual.

Proyecto del curso Modelos y Simulación II, Grupo 5, semestre 2026-2. Departamento de Ingeniería de Sistemas, Facultad de Ingeniería, Universidad de Antioquia, Medellín, Colombia.

Tabla I
Variables del conjunto de datos

Variable	Tipo	Descripción
`transaction_id`	Identificador	Identificador de la transacción
`timestamp`	Temporal	Fecha y hora
`user_id`	Identificador	Identificador del cliente (2 142 valores)
`account_type`	Categórica (3)	Checking, Savings, Credit Card
`category`	Categórica (8)	Groceries, Dining, Travel, Electronics, etc.
`amount`	Numérica	Monto en USD (1,50–1 668,90)
`currency`	Constante	USD
`payment_method`	Categórica (4)	Debit Card, Credit Card, UPI, Bank Transfer
`device_type`	Categórica (4)	Mobile, Desktop, POS Terminal, ATM
`risk_score`	Numérica	Puntaje de riesgo precalculado (0–100)
`is_fraud`	Objetivo	0 = normal, 1 = fraude

II-B. Base de datos

Se usa el conjunto *Financial Transactions & Fraud Detection* de Kaggle [4]: 10 000 transacciones **sintéticas** de 2 142 usuarios, registradas entre el 26 de agosto de 2025 y el 26 de agosto de 2026, descritas por las 11 variables de la Tabla I. No hay valores faltantes, filas duplicadas ni identificadores repetidos. La variable `currency` es constante (USD) y se descarta.

II-C. Análisis exploratorio

Desbalance. Hay 126 fraudes (1,26 %) frente a 9 874 transacciones normales. Un clasificador que nunca prediga fraude alcanzaría una exactitud del 98,7 %, por lo que la exactitud no sirve como criterio de evaluación.

Variables numéricas. El monto es muy asimétrico (asimetría 5,68), por lo que se usa $\log(1+\text{amount})$ (asimetría 0,14). Para medir la capacidad discriminativa se usa la prueba de Mann-Whitney U y el área bajo la curva ROC univariada (AUC). El monto no distingue las clases (medianas de 25,4 y 27,4 USD; $p = 0{,}70$; AUC $= 0{,}49$). El `risk_score` es la única variable con diferencias significativas ($p = 8{,}3 \times 10^{-5}$), pero su AUC es solo 0,60 porque los fraudes forman dos grupos (Fig. 1): 30 fraudes (23,8 %) tienen `risk_score` ≥ 70, mientras que solo el 1,7 % de las transacciones normales supera 65; el resto de fraudes se confunde con las transacciones normales. Una regla con umbral 70 captura el 23,8 % de los fraudes con una precisión del 31,2 %.

Posible fuga de información. El origen de `risk_score` no se documenta. Además, los 30 fraudes con puntaje alto no

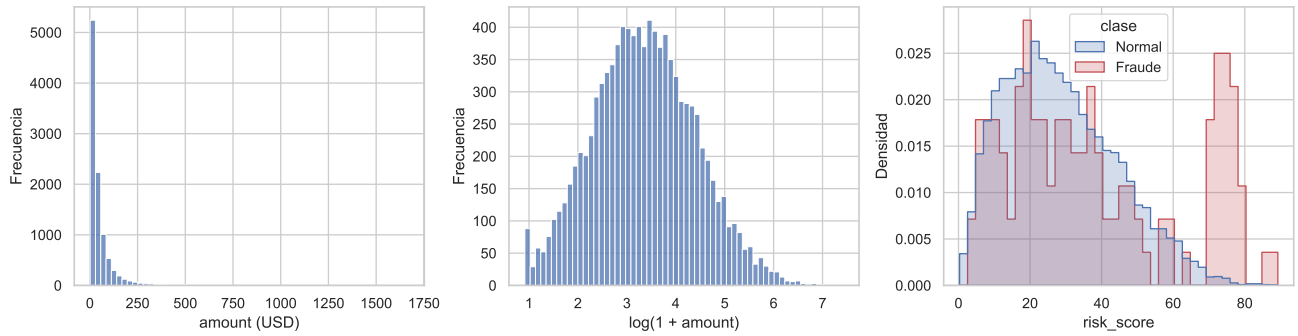


Figura 1. Distribución de `amount` (izquierda) y de $\log(1 + \text{amount})$ (centro), y densidad de `risk_score` por clase (derecha). Los fraudes muestran un segundo grupo con `risk_score` entre 70 y 90.

se diferencian del resto de fraudes en ninguna otra variable (χ^2, $p \geq 0{,}85$; monto, $p = 0{,}58$). Esto es compatible con que el generador sintético haya construido el puntaje a partir de la etiqueta. Por eso los modelos se evaluarán con y sin esta variable.

Variables categóricas. Ninguna se asocia con el fraude según la prueba χ^2 de independencia (`account_type`: $p = 0{,}41$; `category`: $p = 0{,}74$; `payment_method`: $p = 0{,}78$; `device_type`: $p = 0{,}87$). Los intervalos de Wilson al 95 % de todos los niveles contienen la tasa global (Fig. 2).

Variables temporales. Como algunos niveles de hora y mes tienen menos de 5 fraudes esperados, se usa una prueba de permutación (5 000 permutaciones) sobre el estadístico χ^2. Ninguna variable es significativa: hora ($p = 0{,}58$), día de la semana ($p = 0{,}84$), mes ($p = 0{,}38$) y franja horaria ($p = 0{,}34$).

Estructura por usuario. Cada usuario tiene en promedio 4,7 transacciones (máximo 18). Los 126 fraudes se reparten entre 124 usuarios, por lo que el fraude no se concentra en pocos clientes.

Relación entre variables. El `risk_score` no depende de las variables categóricas (Kruskal-Wallis, $p \geq 0{,}34$) ni del monto (Spearman $\rho = 0{,}014$). La Fig. 3 resume el problema: fuera de la franja con `risk_score` ≥ 70, las clases se solapan por completo.

Tabla II
VARIABLES DE COMPORTAMIENTO POR USUARIO

Variable	Definición	AUC
`primera_transaccion`	Primera transacción del usuario	0,48
`transacciones_previas`	N.º de transacciones anteriores	0,51
`horas_desde_anterior_log`	log(1+horas desde la anterior)	0,47
`desvio_log_monto`	Log-monto menos su media histórica	0,55
`transacciones_24h`	Transacciones en las 24 h previas	0,50
`transacciones_7d`	Transacciones en los 7 días previos	0,50
`monto_7d_log`	log(1+monto de los 7 días previos)	0,50
`cambio_dispositivo`	Cambió el dispositivo	0,52
`cambio_metodo_pago`	Cambió el método de pago	0,51
`cambio_categoria`	Cambió la categoría	0,45
`dispositivo_nuevo`	Dispositivo nunca usado antes	0,46

II-D. Fase de caracterización

Los datos no llegan como una matriz de características, sino como un registro de transacciones con marca de tiempo, identificador del cliente y atributos en texto. Por eso se requiere una fase de caracterización que construya el vector de características de cada transacción. Además de las variables de la transacción, se derivan variables temporales (hora en codificación cíclica, $\sin(2\pi h/24)$ y $\cos(2\pi h/24)$, e indicador de fin de semana) y variables de comportamiento del usuario (Tabla II), que en la literatura son de las más útiles para detectar fraude [5]. Todas se calculan usando **solo las transacciones anteriores** del usuario, para no filtrar información del futuro.

Ninguna variable de comportamiento es significativa tras la corrección de Bonferroni ($0{,}05/11 \approx 0{,}0045$); la de menor p es `cambio_categoria` ($p = 0{,}008$), y sus AUC univariadas están entre 0,45 y 0,55. Las variables de ventana casi no varían, porque solo el 1,5 % de las transacciones tiene otra del mismo usuario en las 24 h previas. Aun así, se incorporan al espacio de características como candidatas, porque podrían aportar en combinación con otras variables. Su eliminación se decidirá en el análisis individual de variables de la etapa de reducción de dimensión.

II-E. Preprocesamiento y codificación

Se descartan los identificadores y `currency`, y también el mes, porque el registro cubre un solo año. Las variables categóricas se codifican con *one-hot*, por su baja cardinalidad y la ausencia de orden. El monto se transforma con $\log(1+x)$, y todas las variables no categóricas se estandarizan. Los únicos faltantes los genera la caracterización: en las 2 142 primeras transacciones de cada usuario no están definidas las variables que dependen de una transacción previa. Las continuas se imputan con la mediana y las binarias con 0; el indicador `primera_transaccion` conserva la información de que el valor fue imputado. Imputadores, escaladores y codificadores se ajustan solo con el conjunto de entrenamiento de cada partición, dentro de un *pipeline*. El espacio resultante tiene **35 características**: 10 continuas, 6 binarias y 19 indicadoras *one-hot* (34 sin `risk_score`).

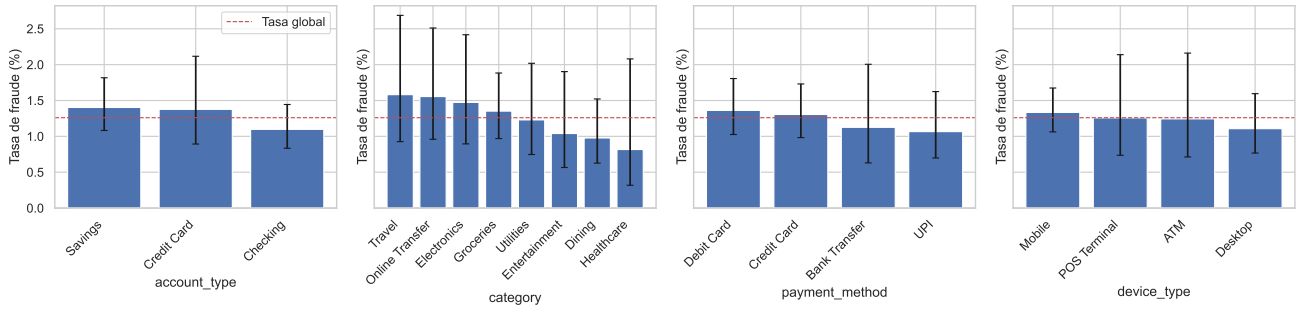


Figura 2. Tasa de fraude por nivel de cada variable categórica con intervalos de confianza de Wilson al 95 %. La línea discontinua marca la tasa global (1,26 %).

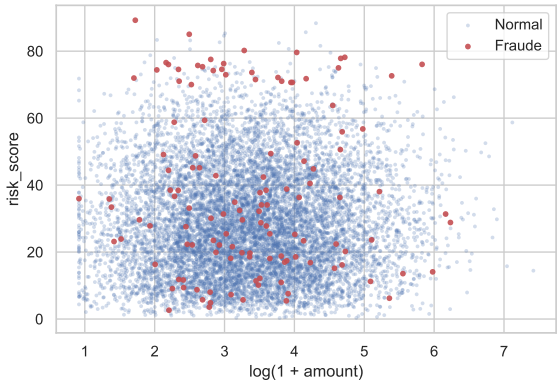


Figura 3. `risk_score` frente a $\log(1 + \text{amount})$ por clase. Fuera de la franja superior, los fraudes se mezclan con las transacciones normales.

II-F. Paradigma de aprendizaje

El problema se aborda como **aprendizaje supervisado de clasificación binaria**, porque todas las transacciones tienen la etiqueta `is_fraud` y el objetivo es predecirla para transacciones nuevas. La detección de anomalías no supervisada se descarta como enfoque principal, porque desperdicia la etiqueta disponible y porque la mayoría de los fraudes de este conjunto no son atípicos (Fig. 3). Los retos principales son el desbalance severo, la señal débil y la posible fuga de información a través de `risk_score`. Por el desbalance, se usarán métricas centradas en la clase positiva, como el área bajo la curva precisión–exhaustividad (PR-AUC).

III. Estado del arte

No se encontraron artículos que usen este conjunto de datos, que es sintético y reciente. Por eso se revisaron artículos de revista (IEEE y Elsevier) que resuelven el mismo problema con otros datos: detectar transacciones fraudulentas como un problema de clasificación desbalanceada (Tabla III).

Métricas no vistas en clase. La **precisión media** (AP o PR-AUC) [6]–[8] resume la curva precisión–exhaustividad: si P_k y R_k son la precisión y la exhaustividad al marcar como fraude las k transacciones de mayor puntaje, $\text{AP} = \sum_k (R_k - R_{k-1}) P_k$. Un modelo aleatorio obtiene una AP igual a la proporción de fraudes (0,0126 en este caso). La **precisión en las k primeras alertas** ($P@k$) [3], [6], [7] es la fracción de fraudes reales entre las k transacciones con mayor puntaje, y refleja que un banco solo puede revisar un número limitado de alertas. El **ahorro** (*savings*) [5] mide la reducción de costo frente a la mejor estrategia sin modelo. Si el costo de un fraude no detectado es su monto y el de revisar una alerta es C_a, entonces $\text{Costo} = \sum_i [y_i(1 - c_i)\,\text{Monto}_i + c_i C_a]$ y $\text{Savings} = (\text{Costo}_0 - \text{Costo})/\text{Costo}_0$.

Implicaciones para este proyecto. Ningún trabajo usa la exactitud como criterio, lo que respalda usar la PR-AUC como métrica principal junto con $P@k$. El balanceo de clases no siempre ayuda [6], [8], por lo que se compararán la ponderación de clases y SMOTE, aplicados solo sobre los datos de entrenamiento. Como los trabajos con fechas validan respetando el tiempo, además de la validación cruzada estratificada se hará una partición temporal. Por último, los trabajos revisados usan millones de transacciones reales, y se ha reportado que los mismos modelos rinden significativamente peor sobre datos simulados que sobre datos reales [9]. Con 126 fraudes sintéticos, se esperan resultados bastante más bajos que los de la literatura.

Referencias

[1] A. Cherif, A. Badhib, H. Ammar, S. Alshehri, M. Kalkatawi, and A. Imine, "Credit card fraud detection in the era of disruptive technologies: A systematic review," *Journal of King Saud University – Computer and Information Sciences*, vol. 35, no. 1, pp. 145–174, 2023.

[2] S. N. Kalid, K.-C. Khor, K.-H. Ng, and G.-K. Tong, "Detecting frauds and payment defaults on credit card data inherited with imbalanced class distribution and overlapping class problems: A systematic review," *IEEE Access*, vol. 12, pp. 23 636–23 652, 2024.

[3] A. Dal Pozzolo, G. Boracchi, O. Caelen, C. Alippi, and G. Bontempi, "Credit card fraud detection: A realistic modeling and a novel learning strategy," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 29, no. 8, pp. 3784–3797, 2018.

[4] "Financial transactions & fraud detection dataset," Kaggle, conjunto de datos sintético. Disponible en: https://www.kaggle.com/datasets/greatcool/financial-transactions-and-fraud-detection-dataset.

[5] A. Correa Bahnsen, D. Aouada, A. Stojanovic, and B. Ottersten, "Feature engineering strategies for credit card fraud detection," *Expert Systems with Applications*, vol. 51, pp. 134–142, 2016.

[6] A. Dal Pozzolo, O. Caelen, Y.-A. Le Borgne, S. Waterschoot, and G. Bontempi, "Learned lessons in credit card fraud detection from a practitioner perspective," *Expert Systems with Applications*, vol. 41, no. 10, pp. 4915–4928, 2014.

[7] F. Carcillo, Y.-A. Le Borgne, O. Caelen, Y. Kessaci, F. Oblé, and G. Bontempi, "Combining unsupervised and supervised learning in credit card fraud detection," *Information Sciences*, vol. 557, pp. 317–331, 2021.

[8] S. Makki, Z. Assaghir, Y. Taher, R. Haque, M.-S. Hacid, and H. Zeineddine, "An experimental study with imbalanced classification approaches for credit card fraud detection," *IEEE Access*, vol. 7, pp. 93 010–93 022, 2019.

Tabla III
TRABAJOS REVISADOS SOBRE DETECCIÓN DE FRAUDE EN TRANSACCIONES

Trabajo	Datos	Paradigma	Técnicas	Validación	Métricas	Resultados
Dal Pozzolo et al., 2018 [3]	Reales: >75 M de transacciones ecommerce (2 datasets, 2013–2015; 0,2 % fraude)	Supervisado sobre flujo de datos	Random Forest con submuestreo; agregación de un modelo con casos recientes y otro con casos antiguos	Temporal: entrenar con días pasados, evaluar el día siguiente	Precisión en las alertas ($P@k$), AUC	Separar feedbacks y muestras retrasadas (AW) eleva la precisión de alertas Pk (k = 100) de 0,61 a 0,77 frente a una ventana que las mezcla (2014–15, = 7)
Correa Bahnsen et al., 2016 [5]	Reales: 236 735 trans. (1,5 % fraude), subconjunto de 120 M	Supervisado sensible al costo	Árbol de decisión, regresión logística, Random Forest y versiones sensibles al costo; variables agregadas y periódicas por cliente	Hold-out entren./valid./prueba: 50/25/25 según el texto (40/30/30 según la Tabla 7)	*Savings*	Las variables periódicas aumentan el ahorro promedio en 13 %
Dal Pozzolo et al., 2014 [6]	Reales: 2,2 M trans. (feb 2012–may 2013; < 0,4 % fraude)	Supervisado	Random Forest, red neuronal y SVM con submuestreo, SMOTE y EasyEnsemble	Temporal por días	AP (PR-AUC), AUC, $P@k$	Random Forest es el mejor; SMOTE y EasyEnsemble superan al submuestreo
Carcillo et al., 2021 [7]	Reales: 76 M trans. (2016; 0,36 % fraude)	Híbrido no supervisado + supervisado	Puntajes de anomalía (Isolation Forest, PCA, etc.) como variables de un Random Forest balanceado	Corte temporal	$P@k$, PR-AUC	Solo el puntaje atípico por clústeres de clientes (uno solo) mejora el AUC-PR; no mejora la precisión Top-100; global y local no mejoran
Makki et al., 2019 [8]	ccFraud: 10 M (5,96 % fraude); experimentos con 199 999 (2 %)	Supervisado	Regresión logística, KNN, SVM, red neuronal, C5.0, Naive Bayes, etc., con sobremuestreo y aprendizaje sensible al costo	Hold-out 70/30 (sobre 199 999)	Exactitud, sensibilidad, PR-AUC	Mejor AUPRC: LR (0,66); peores: KNN y NSA (0,29); los enfoques de desbalance generan más falsas alarmas que fraudes detectados

[9] J. Jemai, A. Zarrad, and A. Daud, "Identifying fraudulent credit card transactions using ensemble learning," *IEEE Access*, vol. 12, pp. 54 893–54 900, 2024.